LSTAT2100 - Exercices - Série 3

Énoncés

Pour ce TP nous allons utiliser les données de 200 patients issus d'un hôpital. Le jeu de données se trouve dans le fichier dt.csv disponible sur "Labs/Data".

Partie 1

Pour l'instant, nous n'utiliserons que les variables suivantes:

- `STA`: Variable binaire indiquant si le patient est décédé (1) ou pas (0).
- `AGE`: L'âge du patient.

Commencez par charger le jeu de données dans R puis *examinez sa structure*.

(a) À partir de la variable `AGE`, créez la variable `AGECAT` qui correspond aux catégories d'âge suivantes:

$$(15-24] \;\; (24-34] \;\; (34-44] \;\; (44-54] \;\; (54-64] \;\; (64-74] \;\; (74-84] \;\; (84-94]$$

Quelle est la proportion de décès par catégorie d'âge? Visualiser graphiquement ces chiffres. Que pouvez-vous conclure quant à l'effet de l'âge sur la survie des patients ?

(b) Réalisez un scatterplot de `STA` versus `AGE`. Ajouter la droite de moindre carrée à votre graphique et calculer le coefficient de détermination (classique).

(c) Écrivez l'équation du modèle logistique reliant `Y=STA` (réponse) et `X=AGE` (prédicteur). *L'événement de "succès" ($Y = 1$) doit être le décès.* Écrivez le log-vraisemblance de votre modèle et maximisez-le ***numériquement*** (sans passer par la fonction `glm()`) en utilisant, par exemple, la fonction `optim()` (voir le Help de R).

(d) Utilisez la fonction `glm` pour estimer le modèle tel que défini en (c). Comparez avec les estimations obtenues auparavant. Visualisez le modèle à l'aide d'un graphique adéquat.

(e) Interprétez les paramètres de votre modèle. Selon ce dernier, quelle est la probabilité de mourir pour une personne âgée de 60 ans ? Construisez un IC à 95% pour cette probabilité.

(f) Utilisez la fonction `fitted()` pour calculer les résidus de la déviance *à l'aide de la formule* qui définit ces derniers (voir le cours). Vérifier vos calculs à l'aide de la fonction `resid()`. Représenter ces résidus graphiquement. Que pouvez-vous en conclure ?

(g) Que pensez-vous de la qualité d'ajustement du modèle ? Répondez à cette question de deux façons différentes: (i) en utilisant les calculs réalisés au point (a); (ii) en utilisant la courbe ROC.

Partie 2

(a) On aimerait ajuster un modèle logistique avec `STA` comme variable expliquée et `CPR` comme variable explicative. En précisant vos notations et en prenant $CPR = 2$ et $STA = 0$ comme niveaux de référence,

(i) réalisez un tableau croisé entre les variables `STA` et `CPR`.
(ii) donnez l'équation théorique du modèle puis
(iii) estimez les paramètres **à la main** *sans la fonction* `glm` *de R*,
(iv) calculez (toujours **à la main**) les intervalles de confiance et
(v) comparer vos résultats avec un ajustement fait avec la fonction `glm`.

(b) Que deviennent les paramètres estimés du modèle si l'on change le niveau de référence pour CPR? Répondez **sans calculs supplémentaires** puis vérifiez à l'aide de R.

(c) Réalisez un tableau croisé entre les variables `STA` et RACE (`RAC` dans le fichier de données; 1 = white, 2 = black, 3 = other). Prenez $RAC = 1$ comme niveau de référence. Calculez les deux log-OR de votre table; vous devez utiliser les groupes de références tel qu'indiqué ci-dessus. Ajustez ensuite un modèle logit avec `STA` comme variable expliquée et `RAC` comme variable explicative. Commentez.

(d) Utlisez le modèle ajusté au point précédent pour tester l'indépendance entre les variables `STA` et `RAC`.

(e) Ajustez un modèle logit avec `STA` comme variable expliquée et `CRN` et `AGE` comme variables explicatives. Prenez $CRN = 2$ comme référence et incluez l'interaction entre `CRN` et `AGE` dans votre modèle. Cette interaction est-elle significative ? Rectifier le modèle si besoin. Utilisez le modèle rectifié pour calculer la probabilité de mourir pour une personne âgée de 30 ans dont $CRN = 2$.

Partie 3

En plus de la variable `AGE`, nous souhaitons ici expliquer la variable `STA` à l'aide des variables `CPR`, `CAN`, `INF`, ainsi que la variable `RAC` qu'on vous demande de *recoder* de façon à ce qu'elle soit dichotomique (1 = white, 0 = black or other); prenez "0" comme référence. Pour `CPR`, `CAN` et `INF`, prenez "2" comme niveau de référence.

(a) Écrivez à la main l'équation complète d'un modèle logistique, sans interactions, incluant les variables citées ci-dessus et estimez les paramètres de ce modèle.

(b) Utilisez les fonction `logLik()` et `pchisq()` pour réaliser un test LR pour tester le modèle actuel (H_1) versus un modèle avec seulement l'intercept (H_0). Vous ne devez utiliser ni la fonction `anova()` ni la fonction `drop1()`. Écrivez explicitement vos hypothèses H_0 et H_1. Que concluez-vous ?

(c) Simplifiez le modèle actuel en supprimant toutes les variables non-significatives à 5%. Effectuez cette simplification étape par étape en supprimant une seule variable à la fois. Écrivez l'équation de votre modèle ainsi estimé.

(d) Maintenant que vous n'avez que des variables explicatives significatives, complétez le modèle ainsi construit en ajoutant toutes les interactions. Peut-on simplifier ce dernier? Utilisez la BIC pour répondre à cette dernière question.

(e) Utilisez le modèle que vous avez choisi pour prédire la probabilité **de survie** pour deux patients avec $AGE = 25$ et $AGE = 80$ et un $CPR =$ "1". Même question avec un $CPR =$ "2". Accompagnez vos calculs des des intervalles de confiance à 95%.

(f) Quel est, selon le modèle que vous avez choisi, l'effet de l'âge sur la probabilité de mourir? Répondez à l'aide d'un **graphique** adéquat. Même question cette fois-ci pour l'effet de la variable `CPR`.